PRML 作业 2 报告

23231044@buaa.edu.cn

报告人：武俊成

摘要

此次作业基于 Python 生成了一个包含非线性特征的 3D Make Moons 数据集，其中训练集包含 1000 个样本，测试集包含与训练集同分布的 500 个样本（均被分为 C0 与 C1 两类）。作业分别采用了**决策树（Decision Trees）**、**自适应提升算法结合决策树（AdaBoost + Decision Trees）**以及**支持向量机（SVM）**对该 3D 数据进行分类拟合。在 SVM 模型中，对比了 **Linear**、**Poly**、**RBF** 和 **Sigmoid** 四种不同的核函数（Kernel Functions）。最终通过**准确率（Accuracy）**、**精确率（Precision）**、**召回率（Recall）**及 **F1-Score** 等指标对各分类器的性能进行了综合评估，得出了相应模型的分类预测图并对算法在复杂非线性拓扑空间中的表现差异进行了深入的对比与分析。

引言

在机器学习中，分类算法的核心在于寻找能够有效划分不同类别数据的决策边界。然而，现实中的数据往往分布在复杂的高维空间中，且类别之间呈现高度的非线性 g 关系。本次作业使用的 3D Make Moons 数据集就是一个典型的非线性二分类问题，其数据在三维空间中呈现出互相咬合的半月形状分布。单一的线性模型难以处理此类问题。本次实验旨在通过三种算法，观察并对比传统决策树、集成学习方法（AdaBoost）以及引入核技巧的 SVM

算法在处理此类复杂 3D 数据时的实际表现，理解不同模型背后的数学几何意义及其适用场景。

研究方法

本次作业主要使用 Python 语言进行编程，通过 NumPy 进行矩阵运算与数据生成，并且利用 scikit-learn（Sklenar）库构建分类模型，最后再使用 matplotlib 进行了结果的可视化。通过自定义的 make_moons_3d 函数，利用三角函数在三维空间中生成互相交错的两条曲线（半月形），并向其中加入标准差为 noise = 0.2 的高斯噪声以模拟真实数据的扰动。最终生成 1000 个训练数据点与 500 个测试数据点，数据点在绘制图上按照颜色分为 C0 与 C1 两类。

方法 1 ： Decision Trees

决策树是一种基于树状结构进行决策的非参数监督学习方法。其算法原理是通过不断选择最优特征对特征空间进行划分，使得划分后的子节点纯度最高。常用的纯度度量指标为基尼不纯度（Gini Impurity）：

$$\mathrm{Gini}(p) = \sum_{k=1}^{K} p_k (1 - p_k) = 1 - \sum_{k=1}^{K} p_k^2 \cdots\cdots\cdots\cdots\cdots\cdots\cdots (1)$$

在代码实现中，直接调用了 DecisionTreeClassifier，并设定最大深度 max_depth = 10 以防止过度拟合。其本质是在 3D 空间中寻找平行于坐标轴的平面来进行空间切割，从而将不同类别的数据划分到不同的子空间中。

方法 2：AdaBoost + Decision Trees

AdaBoost（Adaptive Boosting）是一种迭代的集成学习算法。其核心原理是针对同一个训练集训练多个弱分类器（本次实验中使用决策树作为基分类器），在每次迭代中，算法会增加前一轮分类错误样本的权重，使得后续的

弱分类器更加关注这些“困难”样本。最终通过加权多数表决的方式将它们组合成一个强分类器：

$$H(x) = \text{sign}\left(\sum_{t=1}^{T} \alpha_t \, h_t(x)\right) \cdots\cdots (2)$$

其中 $h_t(x)$ 为第 t 个弱分类器，α_t 为其对应的权重，通常与其错误率相关：

$$\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right) \cdots\cdots (3)$$

其中 $h_t(x)$ 为第 t 个弱分类器，α_t 为其对应的权重，通常与其错误率相关：在代码实现中，调用了 AdaBoostClassifier 并以决策树作为基学习器。为了进一步提升性能，代码引入了 GridSearchCV 进行网格搜索，对弱学习器数量（n_estimators）、学习率（learning_rate）以及基分类器的最大深度（max_depth）进行了参数调优，以获取该分布下的最优超参数组合。最终确定较为理想参数组合为：n_estimators：200、learning_rate：1.0、estimator__max_depth：3

方法 3：SVM

支持向量机（SVM）的基本原理是在特征空间中寻找一个能够将不同类别数据正确划分且间隔（Margin）最大的超平面。其核心的优化目标可以表为：

$$\min_{w,b} \frac{1}{2}||w||^2 \cdots\cdots (4)$$

约束条件为：

$$y_i(w^T\phi(x_i) + b) \geq 1 \cdots\cdots (5)$$

其中 SVM 引入了核技巧（Kernel Trick），通过核函数：

$$K(x_i, x_j) = \phi(x_i)^T\phi(x_j) \cdots\cdots (6)$$

将原始数据隐式地映射到更高维甚至无穷维的空间中，使其变得线性可分。在代码实现中，调用了 SVC 模型，并设置了四种不同的核函进行对比实验。其中包含线性核（Linear Kernel）、多项式核（Polynomial Kernel）、高斯径向基核（RBF Kernel – Radial Basis Function）以及 S 型核（Sigmoid Kernel），四者基本原理如下：

（1） 线性核（Linear Kernel）

线性核将试图在原始特征空间中直接寻找一个平面的决策边界，其数学表达为：

$$K(x,y) = x^T y \cdots\cdots (7)$$

（2） 多项式核（Polynomial Kernel）

它可以计算特征之间的多阶交叉，相当于将空间进行了“弯曲”和“折叠”。多模式核的阶数越高，映射的维度越高，决策边界就越复杂。

$$K(x,y) = (\gamma x^T y + r)^d \cdots\cdots (8)$$

其中 γ为缩放参数，r为偏置项，d为多项式的阶数

（3） 高斯径向基核（RBF Kernel – Radial Basis Function）

RBF 核是 SVM 中最强大、最常用的核函数。从数学级数展开的角度来看，它将原始数据映射到了无限维空间。它本质上是在衡量两个样本点之间的距离（相似度）：距离越近，K 值越趋近于 1；距离越远，K值越趋近于 0

$$K(x,y) = \exp(-\gamma||x-y||^2) \cdots\cdots (9)$$

其中 γ是超参数，控制着高斯分布的宽度。γ 越大，单个样本的影响范围越小，而 γ 越小，影响范围越广。

（4） S 型核（Sigmoid Kernel）

当 SVM 使用 Sigmoid 核时，其数学模型等价于一个包含单个隐藏层的多层感知机（MLP）神经网络。

实验结果与分析

实验结果如下：

Table 1 实验结果表

	Accuracy	Precision	Recall	F1-Score
Decision Trees	0.9610	0.9583	0.9640	0. 9611
AdaBoost	0.9750	0.9798	0.9700	0. 9749
SVM-Linear Kernel	0.6750	0.6754	0.6740	0. 6747
SVM-Polynomial Kernel	0.8580	0.9590	0.7480	0. 8404
SVM-RBF Kernel	0.9850	0.9840	0.9860	0. 9850
SVM-Sigmoid Kernel	0.5810	0.5793	0.5920	0. 5856

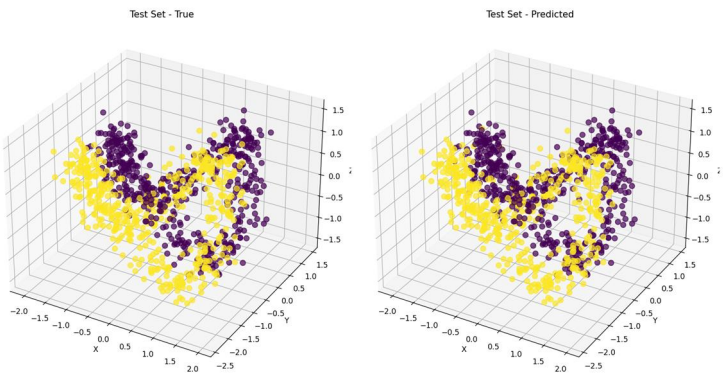

Figure 1 数据集分类图

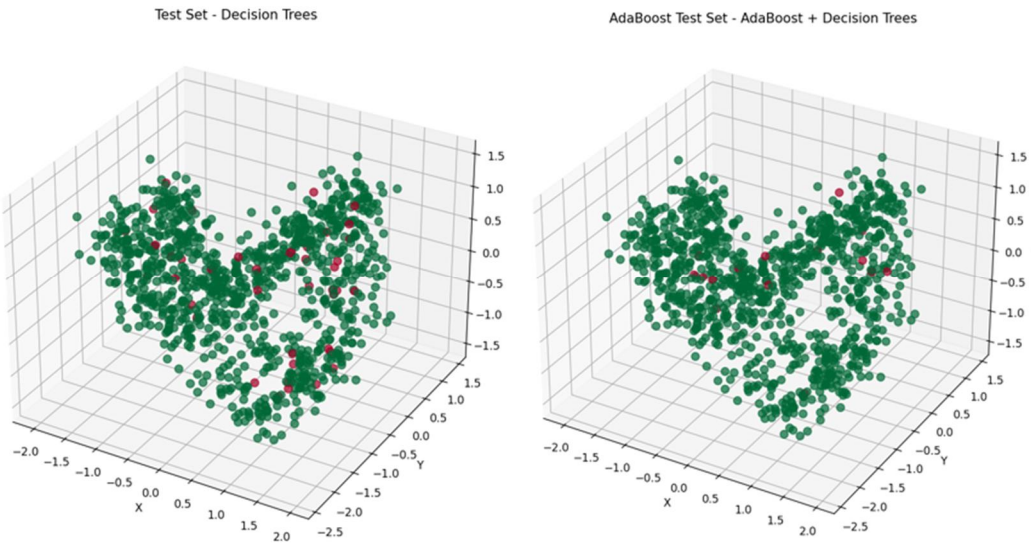

Figure 2 Decision Trees 以及 AdaBoost + Decision Trees 分类效果图（绿色正确、红色错误）

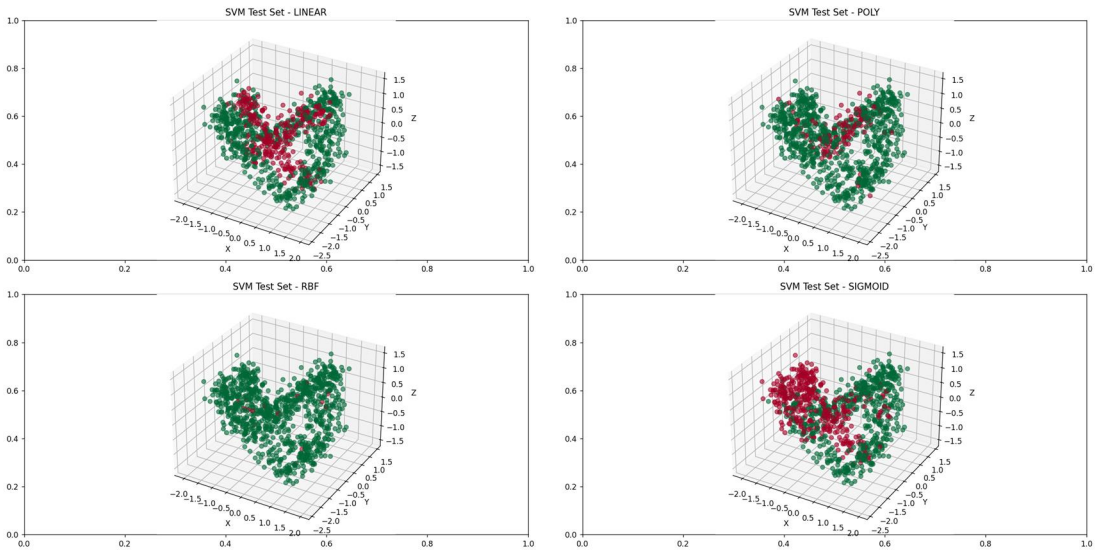

Figure 3 四种 Kernels 分类效果图

结论

通过上述实验结果分析，最终得出以下结论。

首先是 3D Make Moons 数据在三维空间中呈现出互相嵌套与缠绕的形态。这种非线性的拓扑结构使得寻找单一平直划分超平面的尝试彻底失效（如 Linear SVM 准确率仅为 0.6750 且 Sigmoid 核完全失效）。所以，在面对复杂几何分布的数据时，必须需要能够处理非线性边界的算法机制。

其次是单一决策树虽然表现尚可（准确率 0.9610），但由于其本质是依靠平行于坐标轴的平面进行空间“阶梯式”切割，在拟合平滑连续的非线性曲线时容易出现边界僵硬和局部过拟合。引入 AdaBoost 集成机制后，准确率显著提升至 0.9750，这说明了集成模型在降低方差、增强模型泛化能力方有着巨大的优势。

最后是 SVM 模型的对照实验，核函数的选择对最终结果起到了决定性作用。相比于多项式核（Poly）只能捕获部分弧度特征，RBF 核函数取得了全场最佳的分类性能（准确率高达 0.9850）。RBF 核以空间距离（相似度）为度量基础，将原始三维数据隐式映射到无限维的高维特征空间中，完

美契合了该数据集“同类数据在局部空间高度聚集连续”的几何特性，从而在极高维度上找到了异常清晰的线性分割超平面。

综上所述，在处理类似 3D Make Moons 这非线性、边界复杂且互相缠绕的空间分类问题时，采用高斯径向基核（RBF Kernel）的支持向量机是十分不错的解决方案；同时，以决策树为基学习器的 AdaBoost 算法效果也不错，而且可以通过 GridSearchCV 去学习调整参数。